上海财经大学
信息管理与工程学院
《高维数据分析》讲义

第七讲　logistic与非线性回归

袁洪松

内容概要：
logistic回归，广义线性模型，非线性回归

课本章节：
Weisberg Sections 12.1, 12.2, 11.1, 11.2, 11.3

1　Logistic回归

1.1　模型设定

假设由自变量$X_1, \ldots, X_p$, 而因变量Y是表示计数的数据，即Y的取值为非负整数，代表某事件成功的次数。用来刻画Y的一个常见分布为**二项分布 (binomial distribution)**。记试验次数为m，每次试验成功概率为θ的二项分布为$\mathrm{Bin}(m, \theta)$，其分布的概率质量函数为

$$P(Y = j) = \binom{m}{j} \theta^j (1-\theta)^{m-j}, \quad 0 \le j \le m.$$

其期望与方差分别为

$$\mathrm{E}(Y) = m\theta, \quad \mathrm{Var}(Y) = m\theta(1-\theta).$$

若$m = 1$，则此分布为一个成功概率为θ的**Bernoulli分布 (Bernoulli distribution)**，记为$\mathrm{Bernoulli}(\theta)$。可以知道，$\mathrm{Bin}(m, \theta)$为$m$ 个i.i.d.的$\mathrm{Bernoulli}(\theta)$随机变量之和。

对于样本$(x_{11}, \ldots, x_{1p}; y_1), \ldots, (x_{n1}, \ldots, x_{np}; y_n)$，记$\mathbf{x}_i = (x_{i1}, \ldots, x_{ip})^\top$。假设

$$y_i \sim \mathrm{Bin}\left\{m_i, \theta^*(\mathbf{x}_i)\right\}$$
$$\theta^*(\mathbf{x}_i) = K(\beta_0^* + \sum_{j=1}^{p} x_{ij}\beta_j^*), \quad 1 \le i \le n.$$

其中m_i**已知**，$\beta_0^*, \ldots, \beta_p^*$为待估参数。我们把$\beta_0^* + \sum_{j=1}^p x_{ij}\beta_j^*$称为linear predictor，把函数$K(\cdot)$称为kernel mean function，而把$K(\cdot)$的逆函数$K^{-1}(\cdot)$称为link function。

为记号方便，记$\mathbf{z}_i = (1, x_{i1}, \ldots, x_{ip})^\top, \boldsymbol{\beta}^* = (\beta_0^*, \beta_1^*, \ldots, \beta_p^*)^\top$，则$\beta_0^* + \sum_{j=1}^p x_{ij}\beta_j^* = \mathbf{z}_i^\top \boldsymbol{\beta}^*$。若

把$K(\cdot)$取为logistic function $S(z)=e^z/(1+e^z)$，则

$$\theta^*(\mathbf{x}_i)=\frac{\exp(\mathbf{z}_i^\top\boldsymbol{\beta}^*)}{1+\exp(\mathbf{z}_i^\top\boldsymbol{\beta}^*)}.$$

这个回归模型就称为一个**logistic回归模型**。此时link function为$S^{-1}(\theta)=\log\{\theta/(1-\theta)\}$，称为一个logit function，而$\theta/(1-\theta)$称为odds of success。

简单总结一下，二项回归模型的三个要素为：

1) 分布：y_i服从一个二项分布$\mathrm{Bin}\{m_i,\theta^*(\mathbf{x}_i)\}$

2) linear predictor：成功概率$\theta^*(\mathbf{x}_i)$取决于$\mathbf{z}_i^\top\boldsymbol{\beta}^*$

3) link function: $\mathbf{z}_i^\top\boldsymbol{\beta}^*=K^{-1}\{\theta^*(\mathbf{x}_i)\}$

1.2 参数估计

对于logistic回归模型，可以写出似然函数

$$L(\boldsymbol{\beta})=\prod_{i=1}^n\binom{m_i}{y_i}\theta(\mathbf{x}_i)^{y_i}\{1-\theta(\mathbf{x}_i)\}^{m_i-y_i}.$$

而对数似然函数为

$$\begin{aligned}l(\boldsymbol{\beta})&=\sum_{i=1}^n\left[\log\binom{m_i}{y_i}+y_i\log\theta(\mathbf{x}_i)+(m_i-y_i)\log\{1-\theta(\mathbf{x}_i)\}\right]\\&=\sum_{i=1}^n\left[\log\binom{m_i}{y_i}+y_i\log\left\{\frac{\theta(\mathbf{x}_i)}{1-\theta(\mathbf{x}_i)}\right\}+m_i\log\{1-\theta(\mathbf{x}_i)\}\right].\end{aligned}$$

由于$\theta(\mathbf{x}_i)=S(\mathbf{z}_i^\top\boldsymbol{\beta})$，我们知道

$$\begin{aligned}\log\left\{\frac{\theta(\mathbf{x}_i)}{1-\theta(\mathbf{x}_i)}\right\}&=\mathbf{z}_i^\top\boldsymbol{\beta}\\\log\{1-\theta(\mathbf{x}_i)\}&=-\log\{1+\exp(\mathbf{z}_i^\top\boldsymbol{\beta})\}.\end{aligned}$$

于是

$$l(\boldsymbol{\beta})=\sum_{i=1}^n\left[\log\binom{m_i}{y_i}+y_i(\mathbf{z}_i^\top\boldsymbol{\beta})-m_i\log\{1+\exp(\mathbf{z}_i^\top\boldsymbol{\beta})\}\right].$$

最大化似然函数等价于最小化

$$f(\boldsymbol{\beta})=\sum_{i=1}^n\left[m_i\log\{1+\exp(\mathbf{z}_i^\top\boldsymbol{\beta})\}-y_i(\mathbf{z}_i^\top\boldsymbol{\beta})\right].$$

假设$\widehat{\boldsymbol{\beta}}$为一个估计量。对$f$在$\widehat{\boldsymbol{\beta}}$处做Taylor展开，

$$f(\boldsymbol{\beta}) \approx f(\widehat{\boldsymbol{\beta}}) + \left\{\nabla f(\widehat{\boldsymbol{\beta}})\right\}^\top (\boldsymbol{\beta} - \widehat{\boldsymbol{\beta}}) + \frac{1}{2}(\boldsymbol{\beta} - \widehat{\boldsymbol{\beta}})^\top \left\{\nabla^2 f(\widehat{\boldsymbol{\beta}})\right\} (\boldsymbol{\beta} - \widehat{\boldsymbol{\beta}}).$$

可以算出

$$\begin{aligned}
\nabla f(\widehat{\boldsymbol{\beta}}) &= \sum_{i=1}^n m_i \frac{\exp(\mathbf{z}_i^\top \widehat{\boldsymbol{\beta}})}{1 + \exp(\mathbf{z}_i^\top \widehat{\boldsymbol{\beta}})} \mathbf{z}_i - y_i \mathbf{z}_i \\
&= \sum_{i=1}^n \left\{ m_i \widehat{\theta}(\mathbf{x}_i) - y_i \right\} \mathbf{z}_i.
\end{aligned}$$

进一步可以算出

$$\begin{aligned}
\nabla^2 f(\widehat{\boldsymbol{\beta}}) &= \sum_{i=1}^n m_i \frac{\exp(\mathbf{z}_i^\top \widehat{\boldsymbol{\beta}})}{\left\{1 + \exp(\mathbf{z}_i^\top \widehat{\boldsymbol{\beta}})\right\}^2} \mathbf{z}_i \mathbf{z}_i^\top \\
&= \sum_{i=1}^n m_i \widehat{\theta}(\mathbf{x}_i)\{1 - \widehat{\theta}(\mathbf{x}_i)\} \mathbf{z}_i \mathbf{z}_i^\top.
\end{aligned}$$

令

$$\mathbf{Y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{bmatrix} = \begin{bmatrix} \mathbf{z}_1^\top \\ \vdots \\ \mathbf{z}_n^\top \end{bmatrix}.$$

再让$\widehat{\mu}_i = m_i \widehat{\theta}(\mathbf{x}_i)$, $\widehat{w}_i = m_i \widehat{\theta}(\mathbf{x}_i)\{1 - \widehat{\theta}(\mathbf{x}_i)\}$ (注意$\widehat{\mu}_i$与$\widehat{w}_i$分别是二项分布在当前估计处的均值与方差), 以及

$$\widehat{\boldsymbol{\mu}} = \begin{bmatrix} \widehat{\mu}_1 \\ \vdots \\ \widehat{\mu}_n \end{bmatrix}, \quad \widehat{\mathbf{W}} = \begin{bmatrix} \widehat{w}_1 & 0 & \cdots & 0 \\ 0 & \widehat{w}_2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & \widehat{w}_n \end{bmatrix}.$$

则

$$\begin{aligned}
\nabla f(\widehat{\boldsymbol{\beta}}) &= -\mathbf{X}^\top (\mathbf{Y} - \widehat{\boldsymbol{\mu}}) \\
\nabla^2 f(\widehat{\boldsymbol{\beta}}) &= \mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X}.
\end{aligned}$$

所以

$$f(\boldsymbol{\beta}) \approx f(\widehat{\boldsymbol{\beta}}) - (\mathbf{Y} - \widehat{\boldsymbol{\mu}})^\top \mathbf{X} (\boldsymbol{\beta} - \widehat{\boldsymbol{\beta}}) + \frac{1}{2}(\boldsymbol{\beta} - \widehat{\boldsymbol{\beta}})^\top \mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X} (\boldsymbol{\beta} - \widehat{\boldsymbol{\beta}}).$$

右边式子的最小值点为

$$\widehat{\boldsymbol{\beta}}' = \widehat{\boldsymbol{\beta}} + (\mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{Y} - \widehat{\boldsymbol{\mu}}),$$

于是有以下**Iteratively reweighted least squares (IRLS)**算法：

1. 取初值$\widehat{\boldsymbol{\beta}}^{(0)}$，计算$f(\widehat{\boldsymbol{\beta}}^{(0)})$.

2. For $j = 0$ to $J - 1$

   (a) 计算

$$\begin{aligned}
\widehat{\theta}_i^{(j)} &= \frac{\exp(\mathbf{z}_i^\top \widehat{\boldsymbol{\beta}}^{(j)})}{1 + \exp(\mathbf{z}_i^\top \widehat{\boldsymbol{\beta}}^{(j)})} \\
\widehat{\mu}_i^{(j)} &= m_i \widehat{\theta}_i^{(j)} \\
\widehat{w}_i^{(j)} &= m_i \widehat{\theta}_i^{(j)} (1 - \widehat{\theta}_i^{(j)}),
\end{aligned}$$

   从而得到

$$\widehat{\boldsymbol{\beta}}^{(j+1)} = \widehat{\boldsymbol{\beta}}^{(j)} + (\mathbf{X}^\top \widehat{\mathbf{W}}^{(j)} \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{Y} - \widehat{\boldsymbol{\mu}}^{(j)}).$$

   (b) 进一步计算$f(\widehat{\boldsymbol{\beta}}^{(j)})$. 若$|f(\widehat{\boldsymbol{\beta}}^{(j+1)}) - f(\widehat{\boldsymbol{\beta}}^{(j)})|$小于预设的收敛标准$\epsilon > 0$，则停止循环。

   End For

说明：可以证明$f(\boldsymbol{\beta})$是一个凸函数，所以IRLS总是收敛到全局最优解。

1.3 统计推断

在$\boldsymbol{\beta}^*$附近做Taylor展开可得

$$f(\boldsymbol{\beta}) \approx f(\boldsymbol{\beta}^*) - (\mathbf{Y} - \boldsymbol{\mu}^*)^\top \mathbf{X} (\boldsymbol{\beta} - \boldsymbol{\beta}^*) + \frac{1}{2} (\boldsymbol{\beta} - \boldsymbol{\beta}^*)^\top \mathbf{X}^\top \mathbf{W}^* \mathbf{X} (\boldsymbol{\beta} - \boldsymbol{\beta}^*),$$

其中$\mu_i^* = m_i \theta^*(\mathbf{x}_i)$, $w_i^* = m_i \theta^*(\mathbf{x}_i)\{1 - \theta^*(\mathbf{x}_i)\}$，以及

$$\boldsymbol{\mu}^* = \begin{bmatrix} \mu_1^* \\ \vdots \\ \mu_n^* \end{bmatrix}, \quad \mathbf{W}^* = \begin{bmatrix} w_1^* & 0 & \cdots & 0 \\ 0 & w_2^* & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & w_n^* \end{bmatrix}.$$

如果IRLS收敛到一个接近于$\boldsymbol{\beta}^*$的解$\widehat{\boldsymbol{\beta}}$ (n较大时可以证明成立)，则

$$\widehat{\boldsymbol{\beta}} \approx \boldsymbol{\beta}^* + (\mathbf{X}^\top \mathbf{W}^* \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{Y} - \boldsymbol{\mu}^*).$$

考虑到$y_i \sim \mathrm{Bin}(m_i, \theta^*(\mathbf{x}_i))$，则$\mathrm{E}(y_i - \mu_i^*) = m_i\theta^*(\mathbf{x}_i) - \mu_i^* = 0$。于是

$$\begin{aligned}\mathrm{E}(\widehat{\boldsymbol{\beta}}) &\approx \boldsymbol{\beta}^* + \mathrm{E}\left\{(\mathbf{X}^\top\mathbf{W}^*\mathbf{X})^{-1}\mathbf{X}^\top(\mathbf{Y} - \boldsymbol{\mu}^*)\right\} \\ &= \boldsymbol{\beta}^* + (\mathbf{X}^\top\mathbf{W}^*\mathbf{X})^{-1}\mathbf{X}^\top\mathrm{E}(\mathbf{Y} - \boldsymbol{\mu}^*) \\ &= \boldsymbol{\beta}^*,\end{aligned}$$

即$\widehat{\boldsymbol{\beta}}$为渐进无偏的。另外，由于$\mathrm{Var}(y_i - \mu_i^*) = m_i\theta^*(\mathbf{x}_i)\{1 - \theta^*(\mathbf{x}_i)\} = w_i^*$，$\mathrm{Cov}(y_i - \mu_i^*, y_j - \mu_j^*) = 0 \quad (i \neq j)$，则

$$\begin{aligned}\mathrm{Cov}(\widehat{\boldsymbol{\beta}}) &\approx \left\{(\mathbf{X}^\top\mathbf{W}^*\mathbf{X})^{-1}\mathbf{X}^\top\right\}\mathrm{Cov}(\mathbf{Y} - \boldsymbol{\mu}^*)\left\{(\mathbf{X}^\top\mathbf{W}^*\mathbf{X})^{-1}\mathbf{X}^\top\right\}^\top \\ &= (\mathbf{X}^\top\mathbf{W}^*\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{W}^*\mathbf{X}(\mathbf{X}^\top\mathbf{W}^*\mathbf{X})^{-1} \\ &= (\mathbf{X}^\top\mathbf{W}^*\mathbf{X})^{-1}.\end{aligned}$$

我们可以用估计量$\widehat{\mathbf{W}}$替代$\mathbf{W}^*$, 得到协方差矩阵的一个估计

$$\widehat{\mathrm{Cov}}(\widehat{\boldsymbol{\beta}}) = (\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}.$$

让c_{jj}表示矩阵$(\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}$的第$j+1$个对角元 $(0 \leq j \leq p)$，则$\widehat{\beta}_j$的标准误为

$$\mathrm{se}(\widehat{\beta}_j) = \sqrt{c_{jj}}.$$

由此可得近似置信区间，检验的近似拒绝域等 (同线性回归的t-检验)。

logistic回归模型中可以包含分类自变量，例如有一个连续变量X与一个L个类别的分类自变量F，则全模型可以写为

$$Y \sim X + F + X : F$$

对F引入虚拟变量$U_2, \ldots, U_L$, 即可用$\beta_0 + \beta_1 x_i + \sum_{j=2}^{L}\beta_{0j}u_{ij} + \sum_{j=2}^{L}\beta_{1j}u_{ij}x_i$作为linear predictor。

1.4 Deviance

假设logstic回归中得到估计量$\widehat{\boldsymbol{\beta}}$，相应的成功概率为$\widehat{\theta}(\mathbf{x}_i)$。令$\hat{y}_i = m_i\widehat{\theta}(\mathbf{x}_i)$，为拟合出的第$i$条数据的平均成功次数。可以写出对数似然函数

$$\hat{l} = l(\widehat{\boldsymbol{\beta}}) = \sum_{i=1}^{n}\left\{\log\binom{m_i}{y_i} + y_i\log\left(\frac{\hat{y}_i}{m_i}\right) + (m_i - y_i)\log\left(\frac{m_i - \hat{y}_i}{m_i}\right)\right\}.$$

考虑一个"饱和模型" (saturated model)，让每条数据都可以独立拥有自己的成功概率。对第i条数据(m_i, y_i)，成功概率最好的估计为$\hat{\theta}_i^s = y_i/m_i$。此时的对数似然函数为

$$l^s = \sum_{i=1}^{n}\left\{\log\binom{m_i}{y_i} + y_i\log\left(\frac{y_i}{m_i}\right) + (m_i - y_i)\log\left(\frac{m_i - y_i}{m_i}\right)\right\}.$$

两个模型的似然比检验统计量为

$$G^2 = 2(l^s - \hat{l}) = 2\sum_{i=1}^{n}\left\{y_i \log\left(\frac{y_i}{\hat{y}_i}\right) + (m_i - y_i)\log\left(\frac{m_i - y_i}{m_i - \hat{y}_i}\right)\right\}.$$

G^2称为logisitc回归的**deviance**。G^2越小，表明模型拟合得越好。可以证明，当n充分大时，G^2近似服从$\chi^2(n-p-1)$分布。

例 (Weisberg Section 12.2, Blowdown Data)

1.5 分类问题

在logistic回归中，若所有样本都有$m_i = 1$，那么所有因变量y_i都服从Bernoulli分布，只能取值0或者1。可以将$Y = 0$与$Y = 1$视为Y分属的两个不同类别，此时回归问题称为**二分类 (binary classification)** 问题。在实际中的应用包括：根据病人的临床症状，判断病人是否感染疾病；在网络银行中，根据用户的IP地址、操作历史等，决定一项操作是否为诈骗行为，等等。

可以将logistic回归推广至类别超过2的多分类问题。假设Y的取值有d个类别 (即Y是有d个levels的factor)，编号为$\{1,\ldots,d-1\}$, 我们可以建立以下logistic回归模型

$$\begin{aligned}
P(y_i = k) &= \theta^{*(k)}(\mathbf{x}_i), \quad k = 1,\ldots,d \\
\theta^{*(1)}(\mathbf{x}_i) &= \frac{1}{1 + \sum_{\ell=2}^{d}\exp\left(\mathbf{z}_i^\top \boldsymbol{\beta}^{*(\ell)}\right)} \\
\theta^{*(k)}(\mathbf{x}_i) &= \frac{\exp\left(\mathbf{z}_i^\top \boldsymbol{\beta}^{*(k)}\right)}{1 + \sum_{\ell=2}^{d}\exp\left(\mathbf{z}_i^\top \boldsymbol{\beta}^{*(\ell)}\right)}, \quad k = 2,\ldots,d.
\end{aligned}$$

其中$\boldsymbol{\beta}^{*(\ell)} = (\beta_0^{*(\ell)}, \beta_1^{*(\ell)}, \ldots, \beta_p^{*(\ell)})^\top$, $\ell = 2,\ldots,d$为待估参数。实际上，可以将y_i看做试验次数为1，成功概率为$\left\{\theta^{*(1)}(\mathbf{x}_i),\ldots,\theta^{*(d)}(\mathbf{x}_i)\right\}$的**多项分布 (multinomial distribution)**. 进行参数估计时，只需最大化多项分布的似然函数即可。

2 广义线性模型 (不要求)

logistic回归属于一类更广泛的回归模型中的一种。假设因变量Y的分布属于一个**指数分布类 (exponential class)**，其p.d.f.或p.m.f.具有以下的一般形式

$$f(y;\eta,\phi) = \exp\left\{\frac{y\eta - b(\eta)}{a(\phi)} + h(y,\phi)\right\},$$

其中η,ϕ为参数，$b(\eta), a(\phi)$为参数的函数。指数分布类包含正态分布、二项分布、多项分布、Poisson分布、指数分布、Gamma分布等常见分布。

我们可以计算出

$$\mathrm{E}(Y) = b'(\eta), \quad \mathrm{Var}(Y) = a(\phi)b''(\eta).$$

例 (正态分布) 若$Y \sim N(\mu, \sigma^2)$，则Y的p.d.f.为

$$\begin{aligned} f(y) &= \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2\sigma^2}(y-\mu)^2\right\} \\ &= \exp\left\{-\log\sigma - \log\sqrt{2\pi} - \frac{1}{2\sigma^2}(y-\mu)^2\right\} \\ &= \exp\left\{\frac{y\mu - \frac{1}{2}\mu^2}{\sigma^2} - \frac{y^2}{2\sigma^2} - \log\sigma - \log\sqrt{2\pi}\right\}. \end{aligned}$$

我们让$\eta = \mu$, $\phi = \sigma$，而

$$b(\eta) = \frac{1}{2}\eta^2, \quad a(\phi) = \phi^2, \quad h(y, \phi) = -\frac{y^2}{2\sigma^2} - \log\sigma - \log\sqrt{2\pi},$$

则Y的p.d.f.符合指数分布类的一般形式。

例 (二项分布) 若$Y \sim \mathrm{Bin}(m, \theta)$，其中$m$已知，则$Y$的p.m.f.为

$$\begin{aligned} f(y) = P(Y = y) &= \binom{m}{y}\theta^y(1-\theta)^{m-y} \\ &= \exp\left\{\log\binom{m}{y} + y\log\theta + (m-y)\log(1-\theta)\right\} \\ &= \exp\left\{y\log\left(\frac{\theta}{1-\theta}\right) + m\log(1-\theta) + \log\binom{m}{y}\right\}. \end{aligned}$$

我们让$\eta = \log\{\theta/(1-\theta)\}$, $\phi = 1$，而

$$b(\eta) = m\log(1+e^\eta), \quad a(\phi) = 1, \quad h(y, \phi) = \log\binom{m}{y},$$

则Y的p.m.f.符合指数分布类的一般形式。

例 (Poisson分布) 若$Y \sim \mathrm{Po}(\lambda)$，则$Y$的p.m.f.为

$$\begin{aligned} f(y) = P(Y = y) &= \frac{e^{-\lambda}\lambda^y}{y!} \\ &= \exp\left\{-\lambda + y\log\lambda - \log(y!)\right\}. \end{aligned}$$

我们让$\eta = \log\lambda$, $\phi = 1$，而

$$b(\eta) = e^\eta, \quad a(\phi) = 1, \quad h(y, \phi) = \log(y!),$$

则Y的p.m.f.符合指数分布类的一般形式。

假设有数据$(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)$，其中$y_1, \ldots, y_n$来自指数分布类中的某个分布。记$\mathbf{z}_i = (1, x_{i1}, \ldots, x_{ip})^\top$.

假设所有y_i的ϕ参数都相同，而参数η_i与自变量有如下关系：

$$\mathrm{E}(y_i) = b'(\eta_i) = g^{-1}(\mathbf{z}_i^\top \boldsymbol{\beta}^*),$$

则把函数$g(\cdot)$称为一个**link function**。此回归模型称为**广义线性模型 (generalized linear model)**。如果某个$g(\cdot)$使得$\eta_i = \mathbf{z}_i^\top \boldsymbol{\beta}^*$，则此时$g(\cdot)$称为**canonical link**。

例 (正态分布) 假设$y_i \sim N(\eta_i, \phi^2)$，而

$$\mathrm{E}(y_i) = b'(\eta_i) = \eta_i = g^{-1}(\mathbf{z}_i^\top \boldsymbol{\beta}^*).$$

我们取canonical link，即让$g^{-1}(\eta) = \eta$。于是

$$\mathrm{E}(y_i) = \mathbf{z}_i^\top \boldsymbol{\beta}^*.$$

此即为线性回归模型。

例 (二项分布) 假设$y_i \sim \mathrm{Bin}(m_i, \theta_i)$，其中$m_i$已知，$\eta_i = \log\{\theta_i/(1-\theta_i)\}$，而

$$\mathrm{E}(y_i) = m_i\theta_i = m_i \frac{e^{\eta_i}}{1+e^{\eta_i}} = m_i g^{-1}(\mathbf{z}_i^\top \boldsymbol{\beta}^*).$$

若取canonical link，即让$g^{-1}(\eta) = e^\eta/(1+e^\eta)$，则我们得到

$$\theta_i = \frac{\exp(\mathbf{z}_i^\top \boldsymbol{\beta}^*)}{1+\exp(\mathbf{z}_i^\top \boldsymbol{\beta}^*)}.$$

此即为logistic回归模型。

例 (Poisson分布) 假设$y_i \sim \mathrm{Po}(\lambda_i)$，$\eta_i = \log\lambda_i$, 而

$$\mathrm{E}(y_i) = \lambda_i = e^{\eta_i} = g^{-1}(\mathbf{z}_i^\top \boldsymbol{\beta}^*).$$

我们取canonical link，即让$g^{-1}(\eta) = e^\eta$。于是

$$\lambda_i = \exp(\mathbf{z}_i^\top \boldsymbol{\beta}^*).$$

这称为Poisson回归模型。

3 非线性回归

3.1 非线性模型

假设自变量为$\mathbf{x}_1 = (x_{11}, \ldots, x_{1p})^\top, \ldots, \mathbf{x}_n = (x_{n1}, \ldots, x_{np})^\top$，因变量为$y_1, \ldots, y_n$。非线性模型描述为

$$\begin{aligned} y_i &= m(\mathbf{x}_i; \boldsymbol{\theta}^*) + e_i, \quad i = 1, \ldots, n, \\ e_1, \ldots, e_n &\overset{i.i.d.}{\sim} N(0, {\sigma_*}^2). \end{aligned} \tag{1}$$

其中均值函数$m(\mathbf{x}, \boldsymbol{\theta}^*)$为$\mathbf{x}$的非线性函数，$\boldsymbol{\theta}^* = (\theta_1^*, \ldots, \theta_k^*)^\top$为$k$-维参数。

例 假设

$$m(x, \boldsymbol{\theta}^*) = \theta_1^* + \theta_2^* \left\{1 - \exp(-\theta_3^* x)\right\}.$$

相应的自变量为1维，参数为3维。

3.2 参数估计

与线性回归类似，极大似然估计可以转化为最小二乘问题

$$\min_{\boldsymbol{\theta}} f(\boldsymbol{\theta}) = \sum_{i=1}^{n} \left\{y_i - m(\mathbf{x}_i; \boldsymbol{\theta})\right\}^2,$$

但通常没有显示解。

假设$\widehat{\boldsymbol{\theta}}$是一个估计量。由Taylor展开，

$$m(\mathbf{x}_i; \boldsymbol{\theta}) \approx m(\mathbf{x}_i; \widehat{\boldsymbol{\theta}}) + \left\{\frac{\partial m(\mathbf{x}_i; \widehat{\boldsymbol{\theta}})}{\partial \boldsymbol{\theta}}\right\}^\top (\boldsymbol{\theta} - \widehat{\boldsymbol{\theta}}).$$

让$\mathbf{u}_i(\widehat{\boldsymbol{\theta}}) = \partial m(\mathbf{x}_i; \widehat{\boldsymbol{\theta}})/\partial \boldsymbol{\theta} \in \mathbb{R}^k$，则

$$\begin{aligned} f(\boldsymbol{\theta}) &\approx \sum_{i=1}^{n} \left\{y_i - m(\mathbf{x}_i; \widehat{\boldsymbol{\theta}}) - \mathbf{u}_i(\widehat{\boldsymbol{\theta}})^\top (\boldsymbol{\theta} - \widehat{\boldsymbol{\theta}})\right\}^2 \\ &= \sum_{i=1}^{n} \left\{\hat{e}_i - \mathbf{u}_i(\widehat{\boldsymbol{\theta}})^\top (\boldsymbol{\theta} - \widehat{\boldsymbol{\theta}})\right\}^2. \end{aligned}$$

其中$\hat{e}_i = y_i - m(\mathbf{x}_i; \widehat{\boldsymbol{\theta}})$，称为working residual。进一步令

$$\hat{\mathbf{e}} = \begin{bmatrix} \hat{e}_1 \\ \vdots \\ \hat{e}_n \end{bmatrix} \in \mathbb{R}^n, \quad \mathbf{U}(\widehat{\boldsymbol{\theta}}) = \begin{bmatrix} \mathbf{u}_1(\widehat{\boldsymbol{\theta}})^\top \\ \vdots \\ \mathbf{u}_n(\widehat{\boldsymbol{\theta}})^\top \end{bmatrix} \in \mathbb{R}^{n \times k},$$

则

$$f(\boldsymbol{\theta}) \approx \|\hat{\mathbf{e}} - \mathbf{U}(\widehat{\boldsymbol{\theta}})(\boldsymbol{\theta} - \widehat{\boldsymbol{\theta}})\|^2.$$

右边式子的最小值点为

$$\widehat{\boldsymbol{\theta}}' = \widehat{\boldsymbol{\theta}} + \left\{\mathbf{U}(\widehat{\boldsymbol{\theta}})^\top \mathbf{U}(\widehat{\boldsymbol{\theta}})\right\}^{-1} \mathbf{U}(\widehat{\boldsymbol{\theta}})^\top \hat{\mathbf{e}}.$$

由此可得以下**Gauss-Newton法：**

1. 取初值$\widehat{\boldsymbol{\theta}}^{(0)}$，计算$f(\widehat{\boldsymbol{\theta}}^{(0)})$.

2. For $j = 0$ to $J - 1$

   (a) 计算

$$\begin{aligned}
\mathbf{u}_i(\widehat{\boldsymbol{\theta}}^{(j)}) &= \partial m(\mathbf{x}_i; \widehat{\boldsymbol{\theta}}^{(j)})/\partial \boldsymbol{\theta} \\
\hat{e}_i^{(j)} &= y_i - m(\mathbf{x}_i; \widehat{\boldsymbol{\theta}}^{(j)}) \\
\widehat{\boldsymbol{\theta}}^{(j+1)} &= \widehat{\boldsymbol{\theta}}^{(j)} + \left\{\mathbf{U}(\widehat{\boldsymbol{\theta}}^{(j)})^\top \mathbf{U}(\widehat{\boldsymbol{\theta}}^{(j)})\right\}^{-1} \mathbf{U}(\widehat{\boldsymbol{\theta}}^{(j)})^\top \hat{\mathbf{e}}^{(j)}.
\end{aligned}$$

   (b) 计算$f(\widehat{\boldsymbol{\theta}}^{(j+1)})$. 若$|f(\widehat{\boldsymbol{\theta}}^{(j+1)}) - f(\widehat{\boldsymbol{\theta}}^{(j)})|$小于预设的收敛标准$\epsilon > 0$，则停止循环。

   End For

说明：Gauss-Newton算法可能的问题包括：

1) 梯度$\mathbf{u}_i(\widehat{\boldsymbol{\theta}}^{(j)})$在某些问题中难以计算，可能需要较复杂的数值方法。

2) 初始值的选取比较重要，若选取不当则容易陷入局部最优。

3.3 统计推断

我们在$\boldsymbol{\theta}^*$附近作Taylor展开可得

$$m(\mathbf{x}_i; \boldsymbol{\theta}) \approx m(\mathbf{x}_i; \boldsymbol{\theta}^*) + \left\{\frac{\partial m(\mathbf{x}_i; \boldsymbol{\theta}^*)}{\partial \boldsymbol{\theta}}\right\}^\top (\boldsymbol{\theta} - \boldsymbol{\theta}^*).$$

由于$\partial m(\mathbf{x}_i; \boldsymbol{\theta}^*)/\partial \boldsymbol{\theta} = \mathbf{u}_i(\boldsymbol{\theta}^*)$，则

$$\begin{aligned}
f(\boldsymbol{\theta}) &\approx \sum_{i=1}^n \left\{y_i - m(\mathbf{x}_i; \boldsymbol{\theta}^*) - \mathbf{u}_i(\boldsymbol{\theta}^*)^\top (\boldsymbol{\theta} - \boldsymbol{\theta}^*)\right\}^2 \\
&= \sum_{i=1}^n \left\{e_i - \mathbf{u}_i(\boldsymbol{\theta}^*)^\top (\boldsymbol{\theta} - \boldsymbol{\theta}^*)\right\}^2 \\
&= \|\mathbf{e} - \mathbf{U}(\boldsymbol{\theta}^*)(\boldsymbol{\theta} - \boldsymbol{\theta}^*)\|^2.
\end{aligned}$$

假设Gauss-Newton法收敛，得到的估计量为$\widehat{\boldsymbol{\theta}}$，则它是$f(\boldsymbol{\theta})$的近似最小值点。又假设$\widehat{\boldsymbol{\theta}}$充分接近真实参数值$\boldsymbol{\theta}^*$ (此条件只有当n较大时才成立)，则

$$\widehat{\boldsymbol{\theta}} \approx \boldsymbol{\theta}^* + \left\{\mathbf{U}(\boldsymbol{\theta}^*)^\top \mathbf{U}(\boldsymbol{\theta}^*)\right\}^{-1} \mathbf{U}(\boldsymbol{\theta}^*)^\top \mathbf{e}.$$

于是$\widehat{\boldsymbol{\theta}}$的近似分布为

$$N\left(\boldsymbol{\theta}^*, {\sigma_*}^2 \left\{\mathbf{U}(\boldsymbol{\theta}^*)^\top \mathbf{U}(\boldsymbol{\theta}^*)\right\}^{-1}\right)$$

我们可以用$\hat{\sigma}^2 = f(\widehat{\boldsymbol{\theta}})/(n-k)$来估计${\sigma_*}^2$，则$\widehat{\boldsymbol{\theta}}$的协方差的一个估计量为

$$\widehat{\mathrm{Cov}}(\widehat{\boldsymbol{\theta}}) = \hat{\sigma}^2 \left\{\mathbf{U}(\widehat{\boldsymbol{\theta}})^\top \mathbf{U}(\widehat{\boldsymbol{\theta}})\right\}^{-1}.$$

如果用c_{jj}表示矩阵$\left\{\mathbf{U}(\widehat{\boldsymbol{\theta}})^\top \mathbf{U}(\widehat{\boldsymbol{\theta}})\right\}^{-1}$的第$j$个对角元，则$\hat{\theta}_j$的标准误为

$$\mathrm{se}(\hat{\theta}_j) = \hat{\sigma}\sqrt{c_{jj}}.$$

由此可到近似置信区间，检验的近似拒绝域等 (同线性回归的t-检验)。

例 (Weisberg Section 11.3, Turkey Data) 见R程序。