2023 Fall: High-dimensional Data Analysis

Sample Midterm Exam 1

说明：本样卷供同学们参考。正式考试中的题型、题量、侧重点、风格和难度与此样卷类似。

Problem 1. (20 pts) 判断题，请判断以下说法为正确 (T) 或者错误 (F)。

1. 简单线性回归中，若估计值$\widehat{\beta}_1 \neq 0$, 则可推断出因变量与自变量的线性关系一定成立。（ F ）
2. 对于多元线性回归，最小二乘估计量$\widehat{\boldsymbol{\beta}}$服从一个多元正态分布。（ T ）
3. 线性回归的R^2一定在区间$[0,1]$里。（ T ）
4. 若自变量X是连续变量，F是分类变量，则只含主效应的模型$Y \sim X + F$表示的含义是，对F中不同的类别，因变量的均值函数关于X的斜率都相同。（ T ）
5. 对于多项式回归，多项式的次数选取得越大，则拟合出的模型做预测时方差越小，偏差的平方越大。（ F ）
6. 主成分分析中，若前三个主成分代表的“信息量” (即方差) 已经超过50%, 则后面的主成分代表的“信息量”加起来都不可能超过前三个。（ T ）
7. R^2_{adj}可能为负数，但不会超过1.（ T ）
8. 其它因素保持不变时，用AIC不会比用BIC选出的变量多。（ F ）
9. 对$p > n$的数据，只要$\lambda > 0$，岭回归就有解。（ T ）
10. lasso会将最小二乘估计中绝对值较大的系数直接缩减到0。（ F ）

Problem 2. (15 pts) 假设一个简单线性模型中，有$n = 18$, $\bar{x} = 0.4$, $\bar{y} = 2.2$, SXX $= 4$, SXY $= -8$, SYY $= 20$, $R^2 = 0.8$.

1. (5 pts) 计算最小二乘估计值$\widehat{\beta}_0$, $\widehat{\beta}_1$.
2. (5 pts) 求出β_1^*的置信度为95%的置信区间。可以用$t_{0.025}(16) = 2.12$.
3. (5 pts) 对于检验问题

$$H_0 : \beta_1^* = -1.5 \text{ vs } H_1 : \beta_1^* \neq -1.5,$$

给出$t-$检验显著水平为5%的拒绝域，以及p-值的计算表达式，并判断是否应该接受H_0.

Solution:

1. $\widehat{\beta}_1 = \mathrm{SXY}/\mathrm{SXX} = -2$, $\widehat{\beta}_0 = \bar{y} - \widehat{\beta}_1\bar{x} = 3$.

2. 先算出$\mathrm{RSS} = \mathrm{SYY}(1-R^2) = 4$. 于是$\widehat{\sigma}^2 = \mathrm{RSS}/(n-2) = 0.25$, 而$\mathrm{se}(\widehat{\beta}_1) = \widehat{\sigma}/\sqrt{\mathrm{SXX}} = 0.25$. 置信区间为

$$[\widehat{\beta}_1 - \mathrm{se}(\widehat{\beta}_1)t_{0.025}(n-2), \widehat{\beta}_1 + \mathrm{se}(\widehat{\beta}_1)t_{0.025}(n-2)] = [-2.53, -1.47].$$

3. 拒绝域为

$$\left\{ \left| \frac{\hat{\beta}_1 + 1.5}{\mathrm{se}(\hat{\beta}_1)} \right| > t_{0.025}(n-2) \right\}.$$

p-值的计算公式为$2P(t(16) > 2)$. 根据拒绝域判断，应该接受H_0.

Problem 3 (15 pts). 在以X为自变量，Y为因变量的简单线性回归中，假设样本为$(x_1, y_1), \ldots, (x_n, y_n)$, 我们记录回归的$R^2$. 定义$X$与$Y$的样本相关系数为

$$c = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}.$$

试证明：$R^2 = c^2$.

Solution:

首先利用$\widehat{y}_i = \widehat{\beta}_0 + \widehat{\beta}_1 x_i = \bar{y} + \widehat{\beta}_1(x_i - \bar{x}_0)$得到

$$\begin{aligned}
\mathrm{RSS} &= \sum_{i=1}^n (y_i - \widehat{y}_i)^2 = \sum_{i=1}^n \left\{ y_i - \bar{y} - \widehat{\beta}_1(x_i - \bar{x}) \right\}^2 \\
&= \sum_{i=1}^n (y_i - \bar{y})^2 - 2\widehat{\beta}_1 \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x}) + \widehat{\beta}_1^2 \sum_{i=1}^n (x_i - \bar{x})^2 \\
&= \mathrm{SYY} - 2\frac{\mathrm{SXY}}{\mathrm{SXX}}\mathrm{SXY} + \left(\frac{\mathrm{SXY}}{\mathrm{SXX}}\right)^2 \mathrm{SXX} \\
&= \mathrm{SYY} - \frac{\mathrm{SXY}^2}{\mathrm{SXX}}
\end{aligned}$$

因此

$$R^2 = \frac{\mathrm{SYY} - \mathrm{RSS}}{\mathrm{SYY}} = \frac{\mathrm{SXY}^2}{\mathrm{SXX} \cdot \mathrm{SYY}} = c^2.$$

Problem 4 (15 pts). 假设一个单变量的回归模型

$$y_i = f^*(x_i) + e_i, \quad i = 1, \ldots, n.$$

其中$f^*(x) = \beta_0^* + \beta_1^* x + \beta_2^*(x-1)_+$, 而统计误差$e_i$为i.i.d. $N(0, \sigma_*^2)$的随机变量。

1. (4 pts) 一方面可以看出，均值函数$f^*(x)$为一个分段线性函数，即

$$f^*(x) = \begin{cases} a_1 + b_1 x, & \text{if } x \le 1 \\ a_2 + b_2 x, & \text{if } x > 1. \end{cases}$$

请用$\beta_0^*, \beta_1^*, \beta_2^*$表示出$a_1, b_1, a_2, b_2$的值。

2. (6 pts) 另一方面，可以将$f^*(x)$看作是基函数$1, x, (x-1)_+$的线性组合。给定样本$(x_1, y_1) = (-3, 1)$, $(x_2, y_2) = (1, 1)$, $(x_3, y_3) = (2, 2)$, $(x_4, y_4) = (2, 4)$, 请用最小二乘法得到a_1, b_1, a_2, b_2的估计值$\widehat{a}_1, \widehat{b}_1, \widehat{a}_2, \widehat{b}_2$. (计算过程中，如果你不想对一个矩阵求逆，可以改为解一个线性方程组$(\mathbf{X}^\top \mathbf{X})\boldsymbol{\beta} = \mathbf{X}^\top \mathbf{Y}$, 其中$\mathbf{X}, \mathbf{Y}$根据问题取合适的值。)

3. (5 pts) 进一步计算σ_*^2的一个无偏估计$\widehat{\sigma}^2$.

Solution:

1. 可以直接写出$a_1 = \beta_0^*, b_1 = \beta_1^*$, $a_2 = \beta_0^* - \beta_2^*, b_2 = \beta_1^* + \beta_2^*$.

2. 构造多元线性回归的自变量与因变量样本：

$$\mathbf{X} = \begin{bmatrix} 1 & x_1 & (x_1-1)_+ \\ 1 & x_2 & (x_2-1)_+ \\ 1 & x_3 & (x_3-1)_+ \\ 1 & x_4 & (x_4-1)_+ \end{bmatrix} = \begin{bmatrix} 1 & -3 & 0 \\ 1 & 1 & 0 \\ 1 & 2 & 1 \\ 1 & 2 & 1 \end{bmatrix}, \quad \mathbf{Y} = \begin{bmatrix} 1 \\ 1 \\ 2 \\ 4 \end{bmatrix}.$$

可以算出

$$\mathbf{X}^\top \mathbf{X} = \begin{bmatrix} 4 & 2 & 2 \\ 2 & 18 & 4 \\ 2 & 4 & 2 \end{bmatrix}, \quad \mathbf{X}^\top \mathbf{Y} = \begin{bmatrix} 8 \\ 10 \\ 6 \end{bmatrix}.$$

于是，$\widehat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} = [1, 0, 2]^\top$. 那么，$\widehat{a}_1 = \widehat{\beta}_0 = 1$, $\widehat{b}_1 = \widehat{\beta}_1 = 0$, $\widehat{a}_2 = \widehat{\beta}_0 - \widehat{\beta}_2 = -1$, $\widehat{b}_2 = \widehat{\beta}_1 + \widehat{\beta}_2 = 2$.

3. 可以算出$\widehat{\mathbf{Y}} = \mathbf{X}\widehat{\boldsymbol{\beta}} = [1, 1, 3, 3]^\top$. 于是RSS=2. 那么$\widehat{\sigma}^2 = \mathrm{RSS}/(n-3) = 2$.

Problem 5 (15 pts). 假设一个线性回归中，候选的自变量为X_1, X_2, X_3, 样本量为$n = 10$. 我们从一个只有截距的模型开始，用向前选变量法做了三步。下表给出了过程中拟合的四个模型以及相应的RSS： 注意模型(2), (3), (4)也都自然包含了截距。

1. (5 pts) 证明：模型(1)中的RSS即为SYY。

2. (5 pts) 我们知道，adjusted R^2的定义为

$$R^2_{\text{adj}} = 1 - \frac{n-1}{n-k-1}(1 - R^2),$$

序号	模型	RSS
(1)	$Y \sim 1$ (只有截距的模型)	100
(2)	$Y \sim X_2$	40
(3)	$Y \sim X_2 + X_3$	28
(4)	$Y \sim X_2 + X_3 + X_1$	25.2

其中k为模型中包含的自变量个数。试用此准则选出合适的模型。

3. (5 pts) 已知BIC的定义为

$$\mathrm{BIC} = n \log\left(\frac{\mathrm{RSS}}{n}\right) + (k+1)\log n.$$

试用此准则选出合适的模型。(已知：$\exp\left(\frac{\log 10}{10}\right) \approx 1.25$)

Solutions:

1. **模型(1)的目标为**

$$\min_{\beta_0} \sum_{i=1}^{n} (y_i - \beta_0)^2.$$

解为$\widehat{\beta}_0 = \bar{y}$. 因此RSS=$\sum_{i=1}^{n}(y_i - \bar{y})$=SYY.

2. **可以算出 因此选择模型(3)。**

序号	模型	RSS	R^2	R^2_{adj}
(1)	$Y \sim 1$ (只有截距的模型)	100	0	0
(2)	$Y \sim X_2$	40	0.6	0.55
(3)	$Y \sim X_2 + X_3$	28	0.72	0.64
(4)	$Y \sim X_2 + X_3 + X_1$	25.2	0.748	0.622

3. **变量个数为k的模型与变量个数为$k+1$的模型对比，后者更好等价于**

$$n \log\left(\frac{\mathrm{RSS}_1}{n}\right) + (k+1)\log n \geq n \log\left(\frac{\mathrm{RSS}_2}{n}\right) + (k+2)\log n,$$

而这等价于

$$\frac{\mathrm{RSS}_1}{\mathrm{RSS}_2} \geq \exp\left(\frac{\log n}{n}\right)$$

相邻两个模型的RSS比值分别为2.5, 1.43, 1.11。所以选择模型(3)。

Problem 6 (20 pts). 在某种冠心病药物的临床试验中，一共有$n = 9$名患者参与了试验。患者的信息包括血型、是否有家族病史、以及性别，它们都是分类变量，分别记为F_1, F_2, F_3. 患者血型F_1包括{“A”，“B”，“O”}三个类别，家族病史F_2包括{“无”，“有”}两个类别，性别F_3包括{“女”，“男”}两

个类别。用药疗程过后记录下每名患者血管扩张的比例Y, 是为度量疗效的连续型变量。具体的样本值如下：

样本编号	血型	家族病史	性别	Y
1	A	无	女	0.56
2	A	无	男	0.32
3	B	无	女	0.61
4	B	无	男	0.49
5	B	有	女	0.61
6	B	有	男	0.69
7	O	无	男	0.42
8	O	有	女	0.22
9	O	有	女	0.05

在做回归时，我们按照惯例引入虚拟变量$U_{12} = I_{\{F_1=\text{“}B''\}}$, $U_{13} = I_{\{F_1=\text{“}O''\}}$, $U_{22} = I_{\{F_2=\text{“有”}\}}$, $U_{32} = I_{\{F_3=\text{“男”}\}}$.

1. (5 pts) 若希望拟合一个一阶模型：$Y \sim F_1 + F_2 + F_3$. 请写出引入虚拟变量之后，回归的自变量矩阵$\mathbf{X}$ (包括截距项)。

2. (5 pts) 若希望拟合一个二阶模型：$Y \sim F_1 + F_2 + F_3 + F_1 : F_2 + F_2 : F_3 + F_1 : F_3$. 用给出的样本做最小二乘法，会出现什么问题？

3. (5 pts) 如果要用最小二乘法拟合一个三阶模型：$Y \sim F_1 + F_2 + F_3 + F_1 : F_2 + F_2 : F_3 + F_1 : F_3 + F_1 : F_2 : F_3$, 至少需要多少样本？

4. (5 pts) 若拟合一个包含二阶项的模型：$Y \sim F_1+F_2+F_3+F_1 : F_3+F_2 : F_3$，得到以下summary的结果：

	Estimate	Std. Error	t value	Pr($>\|t\|$)
(Intercept)	0.56	0.12	4.66	0.14
血型“B”	0.050	0.17	0.29	0.82
血型“O”	-0.43	0.22	-1.89	0.31
家族病史“有”	0	0.17	0.00	1.00
性别“男”	-0.24	0.17	-1.41	0.39
血型“B”:性别“男”	0.12	0.24	0.50	0.71
血型“O”:性别“男”	0.53	0.28	1.86	0.31
家族病史“有”:性别“男”	0.20	0.24	0.83	0.56

试比较两名属性分别为{“A”,“无”,“男”}与{“B”,“有”,“男”}的新患者，哪个预测出的因变量值会更高。(请忽略关于系数显著性的检验结果，即summary table中所有变量都用上。)

Solutions:

1. 可以直接写出

$$\mathbf{X} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 & 0 \end{bmatrix}$$

2. 二阶模型一共有**10**项 (包含截距)，但样本量只有**9**，普通最小二乘法无法得出解。

3. 三阶模型一共有**12**项，因此需要至少**12**条样本才能用最小二乘法。

4. 患者**1**的预测值为

$$0.56 - 0.24 = 0.32.$$

患者**2**的预测值为

$$0.56 + 0.05 - 0.24 + 0.12 + 0.20 = 0.69.$$