2023 Fall: High-dimensional Data Analysis

说明：本样卷供同学参考考试中的侧重点、风格和难度。正式考试中不会出现方差分析 (Anova) 的内容。

Sample Midterm Exam 2

Problem 1. (12 pts) 判断题，请判断以下说法为正确 (T) 或者错误 (F)。

1. 对于线性回归，总有RSS $\leq$ SYY。
2. 对于简单线性回归，不可能所有的残差$\hat{e}_i$都是正数。
3. 若拟合简单线性模型$Y \sim \log(X)$时，得到的估计值是$\hat{\beta}_0 = 1.4$, $\hat{\beta}_1 = 0.8$，则当X的值加倍时，Y会增加0.8。
4. 对于线性回归，若β_j^*的置信度为$(1-\alpha)$的置信区间包括了0，则检验问题$H_0 : \beta_j^* = 0$ vs $H_1 : \beta_j^* \neq 0$在显著水平α下应该拒绝原假设H_0。
5. 在拟合多项式回归$Y \sim X + \cdots + X^d$时，多项式次数d选的越大，则回归的R^2越大。
6. 若在线性回归中方差有权重$\mathrm{Var}(e_i) = \sigma^2/w_i$，但误用了普通最小二乘估计$\hat{\beta}^{\mathrm{OLS}} = (X^T X)^{-1} X^T Y$，则$\hat{\beta}$，则$\hat{\beta}^{\mathrm{OLS}}$不再是$\beta^*$的无偏估计。

Solutions: TTFFTF

Problem 2. (20 pts) 单项选择题

1. 在简单线性回归中，服从正态分布的量是
   (A) β_0^*
   (B) $\hat{\sigma}$
   (C) $\hat{e}_i$
   (D) RSS

2. 假设你先拟合了一个线性模型$Y \sim X$，但考虑一番过后你决定把自变量与因变量互换，改为拟合$X \sim Y$。两个模型相比，一定不会变的是
   (A) 残差平方和
   (B) 回归平方和
   (C) 截距的正负号
   (D) 斜率的正负号

3. 在多元线性回归中，仅依赖于自变量的观测值矩阵$X \in \mathbb{R}^{n\times(p+1)}$，而不依赖于因变量的观测值向量$Y \in \mathbb{R}^n$的是
   (A) 残差平方和
   (B) R^2
   (C) 自变量的前k个主成分
   (D) 最小二乘估计的标准误

4. 若自变量X是连续变量，F是分类变量，则只含主效应的模型$Y \sim X + F$表示的含义是
   (A) 对F中不同的类别，因变量的均值函数为不同的常数。
   (B) 对F中不同的类别，因变量的均值函数为相同的常数。
   (C) 对F中不同的类别，因变量的均值函数关于X的截距都相同。
   (D) 对F中不同的类别，因变量的均值函数关于X的斜率都相同。

5. 关于主成分分析的说法错误的是
   (A) 主成分都是原变量的线性组合
   (B) 若有p个原变量，则可得到$(p+1)$个主成分
   (C) 第一个主成分所代表的"信息量" (即方差) 最大
   (D) 所有主成分的方差之和等于原变量的方差之和

Solutions: CDCDB

Problem 3 (16 pts). 假设一个简单线性模型中，有$n = 50$, $\bar{x} = 3.5$, $\bar{y} = 10$, SXX $= 9$, SXY $= 18$, SYY $= 48$.

1. (6 pts) 计算最小二乘估计值$\hat{\beta}_0$, $\hat{\beta}_1$。
2. (6 pts) 已知t-分布的上分位数$t_{0.025}(48) = 2.01$。对于检验问题

$$H_0 : \beta_1^* = 1.8 \text{ vs } H_1 : \beta_1^* \neq 1.8,$$

   给出t-检验显著水平为5%的拒绝域，并判断是否应该接受H_0。
3. (4 pts) 计算回归的R^2。

(提示：可以利用公式$\text{RSS} = \text{SYY} - \frac{\text{SXY}^2}{\text{SXX}}$。)

Solution:

1. 可以算出

$$\hat{\beta}_1 = \frac{\text{SXY}}{\text{SXX}} = 2, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x} = 3.$$

2. 首先得到

$$\mathrm{RSS} = \mathrm{SYY} - \frac{\mathrm{SXY}^2}{\mathrm{SXX}} = 12.$$

进一步得到

$$\hat{\sigma}^2 = \frac{\mathrm{RSS}}{n-2} = \frac{1}{4}.$$

于是可知

$$\mathrm{se}(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{\mathrm{SXX}}} = \frac{1}{6}.$$

检验的拒绝域为

$$\left\{ \left| \frac{\hat{\beta}_1 - 1.8}{\mathrm{se}(\hat{\beta}_1)} \right| > t_{0.025}(48) \right\}.$$

根据$|(\hat{\beta}_1 - 1.8)/\mathrm{se}(\hat{\beta}_1)| = 1.2$判断出样本没有落在拒绝域内，故应接受$H_0$.

3. $R^2 = 1 - \frac{\mathrm{RSS}}{\mathrm{SYY}} = 0.75$.

Problem 4 (16 pts). 假设一个多元线性模型，$n = 54$, $p = 3$, $\mathrm{RSS} = 120$, 且

$$(X^TX)^{-1} = \begin{pmatrix} 0.04 & 0.01 & -0.02 & -0.05 \\ 0.01 & 0.60 & -0.06 & -0.50 \\ -0.02 & -0.06 & 0.21 & 0.50 \\ -0.05 & -0.50 & 0.50 & 2.00 \end{pmatrix}, \ X^TY = \begin{pmatrix} 30 \\ -10 \\ 40 \\ -14 \end{pmatrix}.$$

另外知道t-分布的上分位数$t_{0.025}(50) = 2.00$.

1. (8pts) 求出β_1^*置信度为95%的置信区间。
2. (8pts) 求出$\mathrm{se}(\hat{\beta}_1 + 2\hat{\beta}_2 + \hat{\beta}_3)$。

Solution:

1. 可以算出

$$\begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \end{pmatrix} = (X^TX)^{-1}X^TY = \begin{pmatrix} 1 \\ -1.1 \\ 1.4 \\ -4.5 \end{pmatrix}.$$

同时有

$$\hat{\sigma}^2 = \frac{\mathrm{RSS}}{n-p-1} = 2.4.$$

于是

$$\mathrm{se}(\hat{\beta}_1) = \sqrt{2.4 \times 0.6} = 1.2, \quad \mathrm{se}(\hat{\beta}_1) \cdot t_{0.025}(50) = 2.4.$$

β_1^***置信度为95%的置信区间为**

$$[-3.5, 1.3].$$

2. 可以算出

$$\mathrm{se}(\hat{\beta}_1 + 2\hat{\beta}_2 + \hat{\beta}_3) = \hat{\sigma}\sqrt{0.60 + 4 \times 0.21 + 2 - 4 \times 0.06 + 4 \times 0.50 - 2 \times 0.50} = 1.2\sqrt{7}.$$

Problem 5 (18 pts). 为了研究某地空气质量与各种因素的关系，我们收集了如下数据：

- 空气质量指数–Y：连续型因变量
- 季节–A：分类自变量，有四个类别{春, 夏, 秋, 冬}
- 天气–B：分类自变量，有四个类别{晴, 阴, 雨, 雪}
- 时间–C：分类自变量，有三个类别{上午 (4-12点), 下午(12-20点), 晚上(20-4点)}

样本总共$n = 162$条。我们拟合回归模型

$$Y \sim A + B + C + A : B + A : C + B : C + A : B : C.$$

1. (4 pts) 请指出在输入*summary()*命令时，结果中主效应项、二阶交互项、三阶交互项分别会有多少项。

2. (10 pts) 当输入*Anova()*命令时，我们得到如下 (部分) 结果 请填充表中缺失的数字(a)–(e)。列

	Sum Sq	Mean Sq	F value	Pr($>F$)	F crit
A	59.49	19.83	(**a**)	0.00 ***	2.68
B	28.58	(**b**)	(**c**)	0.00 ***	2.68
C	0.68	0.34	2.67	0.07	3.08
A:B	5.78	0.64	5.05	0.00 ***	1.96
A:C	1.42	0.24	1.86	0.09	2.18
B:C	1.75	0.29	2.29	0.04 *	(**d**)
A:B:C	1.24	0.07	0.54	0.93	1.70
Residuals	14.5	(**e**)			

式即可，不必计算最后结果。

3. (4 pts) 按照方差分析的结果，请在5%显著水平下确定最后应采用的模型。

Solutions:

1. 主效应项有9项，二阶交互项有21项，三阶交互项有18项。一共48项

2.

$$(e) = 14.5/(162 - 48)$$
$$(a) = 19.83/(e)$$
$$(b) = 28.58/3$$
$$(c) = (b)/(e)$$
$$(d) = 2.18$$

3. 应取模型$Y \sim A + B + C + A : B + B : C$。

Problem 6 (18 pts). 假设真实模型为一个包含三个自变量，且不带截距的线性模型

$$y_i = \beta_1^* x_{i1} + \beta_2^* x_{i2} + \beta_3^* x_{i3} + e_i, \quad 1 \le i \le n,$$

其中统计误差e_i为i.i.d. $N(0, \sigma^2)$的随机变量。现在某研究者忽略了第三个变量，仅用前两个变量做最小二乘法：

$$\min_{\beta_1, \beta_2} \sum_{i=1}^{n} (y_i - \beta_1 x_{i1} - \beta_2 x_{i2})^2 .$$

记此最小二乘法的解为$\widetilde{\beta}_1, \widetilde{\beta}_2$。

1. (6 pts) 假设$\sum_{i=1}^n x_{i1} x_{i2} = 0$。求出$\widetilde{\beta}_1, \widetilde{\beta}_2$的表达式。(不要用矩阵形式表示)
2. (6 pts) 若在1中的假设成立的同时，另外假设$\sum_{i=1}^n x_{i1} x_{i3} = \sum_{i=1}^n x_{i2} x_{i3} = 0$。请证明在1中求出的$\widetilde{\beta}_1, \widetilde{\beta}_2$分别为$\beta_1^*$与$\beta_2^*$的无偏估计。
3. (6 pts) 若1中的假设不一定成立，但2中的假设成立，请证明最小二乘法的解$\widetilde{\beta}_1, \widetilde{\beta}_2$仍然是$\beta_1^*$与$\beta_2^*$的无偏估计。

Solutions:

1. 最小二乘的目标函数可以转化为

$$\begin{aligned}
&\sum_{i=1}^{n} (y_i - \beta_1 x_{i1} - \beta_2 x_{i2})^2 \\
&= \sum_{i=1}^{n} \left(y_i^2 + \beta_1^2 x_{i1}^2 + \beta_2^2 x_{i2}^2 - 2\beta_1 x_{i1} y_i - 2\beta_2 x_{i2} y_i + 2\beta_1 \beta_2 x_{i1} x_{i2} \right) \\
&= \sum_{i=1}^{n} y_i^2 + \beta_1^2 \sum_{i=1}^{n} x_{i1}^2 + \beta_2^2 \sum_{i=1}^{n} x_{i2}^2 - 2\beta_1 \sum_{i=1}^{n} x_{i1} y_i - 2\beta_2 \sum_{i=1}^{n} x_{i2} y_i + 2\beta_1 \beta_2 \sum_{i=1}^{n} x_{i1} x_{i2} \\
&= \sum_{i=1}^{n} y_i^2 + \left(\beta_1^2 \sum_{i=1}^{n} x_{i1}^2 - 2\beta_1 \sum_{i=1}^{n} x_{i1} y_i \right) + \left(\beta_2^2 \sum_{i=1}^{n} x_{i2}^2 - 2\beta_2 \sum_{i=1}^{n} x_{i2} y_i \right).
\end{aligned}$$

于是可分别优化含β_1的部分与含β_2的部分。最后得到的解为

$$\widetilde{\beta}_1 = \frac{\sum_{i=1}^n x_{i1}y_i}{\sum_{i=1}^n x_{i1}^2}, \quad \widetilde{\beta}_2 = \frac{\sum_{i=1}^n x_{i2}y_i}{\sum_{i=1}^n x_{i2}^2}.$$

2. 对于$\widetilde{\beta}_1$，我们有

$$\begin{aligned}\widetilde{\beta}_1 &= \frac{\sum_{i=1}^n x_{i1}\left(\beta_1^* x_{i1} + \beta_2^* x_{i2} + \beta_3^* x_{i3} + e_i\right)}{\sum_{i=1}^n x_{i1}^2} \\ &= \frac{\beta_1^* \sum_{i=1}^n x_{i1}^2 + \beta_2^* \sum_{i=1}^n x_{i1}x_{i2} + \beta_3^* \sum_{i=1}^n x_{i1}x_{i3} + \sum_{i=1}^n x_{i1}e_i}{\sum_{i=1}^n x_{i1}^2} \\ &= \beta_1^* + \frac{\sum_{i=1}^n x_{i1}e_i}{\sum_{i=1}^n x_{i1}^2}.\end{aligned}$$

故

$$\mathrm{E}(\widetilde{\beta}) = \beta_1^* + \frac{\sum_{i=1}^n x_{i1}\mathrm{E}(e_i)}{\sum_{i=1}^n x_{i1}^2} = \beta_1^*.$$

对于$\widetilde{\beta}_1$同理。

3. 我们转为用矩阵表达。记

$$Z_1 = \begin{pmatrix} x_{11} & x_{12} \\ \vdots & \vdots \\ x_{n1} & x_{n2} \end{pmatrix}, \quad Z_2 = \begin{pmatrix} x_{13} \\ \vdots \\ x_{n3} \end{pmatrix}, \quad \widetilde{b} = \begin{pmatrix} \widetilde{\beta}_1 \\ \widetilde{\beta}_2 \end{pmatrix}, \quad b^* = \begin{pmatrix} \beta_1^* \\ \beta_2^* \end{pmatrix}$$

参数可估计，需要Z_1为满秩 (等价条件为$\left(\sum_{i=1}^n x_{i1}^2\right)\left(\sum_{i=1}^n x_{i1}^2\right) > \left(\sum_{i=1}^n x_{i1}x_{i2}\right)^2$)。则按照最小二乘法的解，$\widetilde{b} = (Z_1^T Z_1)^{-1} Z_1^T Y$。而原模型为$Y = Z_1 b^* + Z_2\beta_3^* + e$，所以

$$\begin{aligned}\widetilde{b} &= (Z_1^T Z_1)^{-1} Z_1^T (Z_1 b^* + Z_2\beta_3^* + e) \\ &= b^* + (Z_1^T Z_1)^{-1} Z_1^T Z_2\beta_3^* + (Z_1^T Z_1)^{-1} Z_1^T e.\end{aligned}$$

根据**2**中的假设，

$$Z_1^T Z_2 = \begin{pmatrix} \sum_{i=1}^n x_{i1}x_{i3} \\ \sum_{i=1}^n x_{i2}x_{i3} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

故

$$\mathrm{E}(\widetilde{b}) = b^* + (Z_1^T Z_1)^{-1} Z_1^T \mathrm{E}(e) = b^*.$$