2024 Fall: High-dimensional Data Analysis

Sample Midterm Exam

说明：本样卷供同学们参考。正式考试中的风格和难度与此样卷类似，题型可能会加上选择题。

Problem 1 (20 pts). 判断题，请判断以下说法为正确 (T) 或者错误 (F)。

1) 对于简单线性回归，拟合的回归线一定经过数据的中心点$(\bar{x}, \bar{y})$。（ T ）

2) 回归$Y \sim X_1$的RSS一定不大于$Y \sim X_1 + X_2$的RSS。（ F ）

3) 对于多元线性回归，RSS符合一个卡方分布。（ F ）

4) 若F为一个d个类别的factor，则回归$Y \sim F$的t-统计量的自由度为d。（ F ）

5) 向前选变量法 (forward selection) 不适用于$p > n$的情况。（ F ）

6) 一般来说，模型的灵活度越高，预测时方差越小，偏差越大。（ F ）

7) 对于线性回归的lasso方法，随着tuning parameter λ的增加，选出的变量个数会逐渐减少。（ T ）

8) 非线性回归的Gauss-Newton法一定可以收敛到似然函数的极大值点。（ F ）

9) 对于logistic回归模型，回归的G^2 (deviance) 越小，说明模型拟合得越好。（ T ）

10) 在logistic回归中，若Y为因变量，θ为成功概率，那么odds of success $\theta/(1-\theta)$可以表示为自变量的线性函数。（ F ）

Problem 2 (20 pts) . 假设一个多元线性模型，$n = 8, p = 3$, 样本值在表1中给出。另外知道t-分布的上分位数$t_{0.025}(4) = 2.78$.

表 1: 样本值

样本	X_1	X_2	X_3	Y
1	$1/\sqrt{8}$	$1/\sqrt{8}$	$1/\sqrt{8}$	-1
2	$1/\sqrt{8}$	$1/\sqrt{8}$	$-1/\sqrt{8}$	-1
3	$1/\sqrt{8}$	$-1/\sqrt{8}$	$1/\sqrt{8}$	2
4	$1/\sqrt{8}$	$-1/\sqrt{8}$	$-1/\sqrt{8}$	2
5	$-1/\sqrt{8}$	$1/\sqrt{8}$	$1/\sqrt{8}$	-1
6	$-1/\sqrt{8}$	$1/\sqrt{8}$	$-1/\sqrt{8}$	-1
7	$-1/\sqrt{8}$	$-1/\sqrt{8}$	$1/\sqrt{8}$	2
8	$-1/\sqrt{8}$	$-1/\sqrt{8}$	$-1/\sqrt{8}$	-2

1) (7 pts) 请求出最小二乘估计量$\widehat{\boldsymbol{\beta}}$.

2) (7 pts) 请求出β_1^*置信水平为95%的置信区间。

3) (6 pts) 若采用$\lambda = 2$的lasso，请求出估计量$\widehat{\boldsymbol{\beta}}^{\text{lasso}}$.

答案：

1) 首先可以求出

$$\mathbf{X}^\top\mathbf{X} = \begin{bmatrix} 8 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad \mathbf{X}^\top\mathbf{Y} = \begin{bmatrix} 0 \\ \sqrt{2} \\ -2\sqrt{2} \\ \sqrt{2} \end{bmatrix}$$

因此，

$$\widehat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{Y} = \begin{bmatrix} 0 \\ \sqrt{2} \\ -2\sqrt{2} \\ \sqrt{2} \end{bmatrix}.$$

2) 首先可以求出拟合值

$$\widehat{\mathbf{Y}} = \mathbf{X}\widehat{\boldsymbol{\beta}} = (0, -1, 2, 1-1, -2, 1, 0)^\top.$$

因此，$\text{RSS} = \|\mathbf{Y} - \widehat{\mathbf{Y}}\|^2 = 8$。从而$\hat{\sigma}^2 = \text{RSS}/(n-p-1) = 2$。

接下来，我们有

$$\text{Cov}(\widehat{\boldsymbol{\beta}}) = \hat{\sigma}^2(\mathbf{X}^\top\mathbf{X})^{-1} = \begin{bmatrix} 1/4 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 2 \end{bmatrix}.$$

因此，$\text{se}(\hat{\beta}_1) = \sqrt{2}$. 最后得到$\beta_1^*$置信水平为95%的置信区间为

$$[\widehat{\beta}_1 \pm \text{se}(\hat{\beta}_1)t_{0.025}(4)] = [\sqrt{2} - 2.78\sqrt{2}, \quad \sqrt{2} + 2.78\sqrt{2}].$$

3) 由于所有变量样本均值都是0，因此可以直接用原数据做lasso。而所有自变量都是单位正交的，因此lasso解符合缩减特性：

$$\hat{\beta}_j^{\text{lasso}} = \begin{cases} \text{sign}\left(\widehat{\beta}_j\right)\left(|\widehat{\beta}_j| - \lambda\right), & \text{if } |\widehat{\beta}_j| \geq \lambda \\ 0, & \text{if } |\widehat{\beta}_j| < \lambda. \end{cases}$$

当$\lambda = 2$时，缩减后的解为$\widehat{\mathbf{b}}^{\text{lasso}} = (0, -2\sqrt{2}+2, 0)^\top$．再加上截距$\hat{\beta}_0^{\text{lasso}} = \bar{y} - \sum_{j=1}^{p} \hat{\beta}_j^{\text{lasso}} \bar{x}_j = 0$，最后的lasso解为

$$\widehat{\boldsymbol{\beta}}^{\text{lasso}} = (0, 0, -2\sqrt{2}+2, 0)^\top$$

Problem 3 (16 pts). 假设一个线性回归模型可能包含两个自变量X_1,X_2。若只包含X_1，得到$\text{RSS}_1 = 21$。若只包含X_2，得到$\text{RSS}_2 = 24$。若同时包含X_1,X_2，则得到$\text{RSS}_3 = 15$。另外已知$n = 10$。

1) (8 pts) 根据AIC的定义

$$\text{AIC} = n \log\left(\frac{\text{RSS}}{n}\right) + 2(k+1),$$

试用AIC作为准则，决定应该使用哪个模型。(已知：$e^{0.2} = 1.221$)

2) (8 pts) 根据Adjusted R^2的定义

$$R^2_{adj} = 1 - \frac{n-1}{n-k-1}(1-R^2),$$

试用Adjusted R^2作为准则，决定应该使用哪个模型。

答案：

1) 首先，因为只包含X_2的模型与只包含X_1的模型相比，变量数相同但RSS更大，因此可以直接排除只包含X_2的模型。剩下两个模型相比时，可以根据给出的数字得到

$$10 \log\left(\frac{21}{10}\right) + 4 > 10 \log\left(\frac{15}{10}\right) + 6.$$

因此选择同时包含X_1与X_2的模型。

2) R^2_{adj}还可以表达为

$$R^2_{adj} = 1 - \frac{n-1}{n-k-1} \cdot \frac{\text{RSS}}{\text{SYY}}.$$

当SYY不变时，我们有

$$1 - \frac{9}{8} \cdot \frac{21}{\text{SYY}} < 1 - \frac{9}{7} \cdot \frac{15}{\text{SYY}}.$$

因此仍然选择同时包含X_1与X_2的模型。

Problem 4 (18 pts). 有一批信用卡数据，样本量为$n = 300$，数据包含了每位用户的以下信息：

- X: 收入，为连续变量；
- F：教育程度，为分类变量，共分为“高等 (A)”、“中等 (B)”、“初等 (C)”三个级别；

- Y：是否存在逾期行为，为0/1变量。若存在逾期行为，则取值为1；反之则取值为0。

现在拟合一个logistic回归模型$Y \sim X + F + X : F$，得到表2中的summary结果。我们忽略关于系数显著性的检验结果，即summary中所有变量都用上。

表 2: Summary table

	Estimate	Std. Error	z value	Pr($>\|z\|$)
(Intercept)	2.02	1.53	1.32	0.19
X	-2.07	1.05	-1.97	0.05
B	1.47	**(a)**	4.44	0.00
C	0.28	1.83	0.15	0.88
$X : B$	-1.68	0.66	-2.54	0.01
$X : C$	-1.82	0.96	-1.89	0.06
Null Deviance: 255.97 on 399 degrees of freedom				
Residual deviance: 132.11 on **(b)** degrees of freedom				

1) (6 pts) 将表中的(a)(b)用给出的数字补充完整，可以只列式不计算。另外请仅用表中数字给出变量X的系数β_1^*置信水平为95%的置信区间。

2) (6 pts) 若有一个新用户，其收入为$x_{\text{new}} = 20,000$，教育水平为“中等”。试用表中的数据给出其逾期的概率。可以只列式不计算。

3) (6 pts) 如果把Y的定义颠倒，即若存在逾期行为，则Y取0，反之则Y取1。再拟合logistic回归模型时，是否所有的回归系数恰好为原来值的相反数？请说明理由。

答案:

1) (a)=1.47/4.44; (b)=$n - 6 = 294$. 而从表中可以知道，$t_{0.025}(294) = 1.97$。因此β_1^*置信水平为95%的置信区间为

$$[\widehat{\beta}_1 \pm \text{se}(\widehat{\beta}_1) t_{0.025}(294)] = [-2.07 \pm 1.05 \times 1.97] = [-2.07 \pm 2.07] = [-4.14, 0].$$

2) 首先计算linear predictor

$$\eta_{\text{new}} = \text{z}_{\text{new}}^\top \widehat{\boldsymbol{\beta}} = 2.02 - 2.07 \times 20000 + 1.47 - 1.68 \times 20000.$$

逾期的概率即为

$$\frac{e^{\eta_{\text{new}}}}{1 + e^{\eta_{\text{new}}}}.$$

3) 是的。把原数据的linear predictor记为η_i，那么当所有的回归系数都取为相反数时，linear predictor会变为$-\eta_i$，而成功概率会变为

$$\frac{e^{-\eta_i}}{1 + e^{-\eta_i}} = \frac{1}{1 + e^{\eta_i}}.$$

恰好为原来的失败概率。因此原数据的极大似然估计值取相反数以后正好也为新数据的极大似然估计值。

Problem 5 (14 pts). 假设一个简单线性模型

$$y_i = \beta_0^* + \beta_1^* x_i + e_i, \quad 1 \le i \le n,$$

其中$e_i \overset{i.i.d.}{\sim} N(0, \sigma_*^2)$. 假设用最小二乘法得出的估计值为$\hat{\beta}_0, \hat{\beta}_1$, 回归的$R^2$记为$r^2$。假设我们对数据进行如下变换

$$y_i' = \frac{y_i - c_1}{d_1}, \quad x_i' = \frac{x_i - c_2}{d_2}.$$

然后用数据$(x_1', y_1'), \ldots, (x_n', y_n')$进行最小二乘估计，得到估计值$\hat{\beta}_0', \hat{\beta}_1'$，以及$R^2$的值$r'^2$。

1) (7 pts) 试推出$\hat{\beta}_0', \hat{\beta}_1'$与$\hat{\beta}_0, \hat{\beta}_1$的关系。

2) (7 pts) 证明$r^2 = r'^2$。

答案:

1) 对于任何β_0, β_1，我们有

$$\begin{aligned} y_i - \beta_0 - \beta_1 x_i &= (d_1 y_i' + c_1) - \beta_0 - \beta_1 (d_2 x_i' + c_2) \\ &= d_1 \left\{ y_i' - \frac{\beta_0 - c_1 + c_2\beta_1}{d_1} - \frac{d_2\beta_1}{d_1} x_i' \right\} \end{aligned}$$

因此最小二乘的解应该有对应关系

$$\begin{aligned} \hat{\beta}_0' &= \frac{\hat{\beta}_0 - c_1 + c_2\hat{\beta}_1}{d_1} \\ \hat{\beta}_1' &= \frac{d_2}{d_1}\hat{\beta}_1. \end{aligned}$$

2) 根据1)中的推导，最小二乘的目标函数之间有d_1^2的倍数关系，因此RSS=d_1^2RSS'。其次，我们知道

$$\mathrm{SYY} = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n \{d_1 y_i' + c_1 - (d_1 \bar{y}' + c_1)\}^2 = d_1^2 \sum_{i=1}^n (y_i' - \bar{y}')^2 = d_1^2 \mathrm{SYY}'.$$

因此，

$$r^2 = 1 - \frac{\mathrm{RSS}}{\mathrm{SYY}} = 1 - \frac{\mathrm{RSS}'}{\mathrm{SYY}'} = r'^2.$$

Problem 6 (12 pts). 假设有q个随机变量组成的一个随机向量$\mathbf{W} = (W_1, \ldots, W_q)^\top$, 它的协方差矩阵为$\mathrm{Cov}(\mathbf{W}) = \Sigma$.

1) (4 pts) 从$\mathbf{W}$出发，我们构造p个自变量$X_1, \ldots, X_p$，其中$p > q$。具体如下：

$$\begin{aligned} X_1 &= a_{11}W_1 + \cdots + a_{1q}W_q \\ &\cdots \\ X_p &= a_{p1}W_1 + \cdots + a_{pq}W_q, \end{aligned}$$

其中a_{ij}均为取定的常数。

记$\mathbf{X} = (X_1, \ldots, X_p)^\top$, 同时记

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1q} \\ & \cdots & \\ a_{p1} & \cdots & a_{pq} \end{bmatrix} \in \mathbb{R}^{p \times q}.$$

注意到$\mathbf{X}$的协方差矩阵为$\mathrm{Cov}(\mathbf{X}) = A\Sigma A^\top$. 现在对这$p$个自变量$X_1, \ldots, X_p$进行主成分分析。试证明：只存在$q$个有效的主成分 (即前$q$个主成分代表了自变量的全部信息)。

2) (4 pts) 现在假设1)中$\mathbf{X}$对$\mathbf{W}$的依赖关系中有一些随机扰动：

$$\begin{aligned} X_1 &= a_{11}W_1 + \cdots + a_{1q}W_q + \epsilon_1 \\ &\cdots \\ X_p &= a_{p1}W_1 + \cdots + a_{pq}W_q + \epsilon_p, \end{aligned}$$

其中$\epsilon_1, \ldots, \epsilon_p$为 i.i.d. $N(0, \tau^2)$分布的随机变量，且均与$\mathbf{W}$互相独立。此时再对这p个自变量$X_1, \ldots, X_p$进行主成分分析。试证明：此时$\mathrm{Cov}(\mathbf{X})$的前q个特征值为

$$\lambda_1 + \tau^2 \geq \cdots \geq \lambda_q + \tau^2,$$

其中$\lambda_1 \geq \cdots \geq \lambda_q$为$A\Sigma A^\top$的前$q$个特征值。

3) (4 pts) 延续2)中的设定。试证明：前q个主成分代表的信息占总信息的比例为

$$\frac{\sum_{i=1}^q \lambda_i + q\tau^2}{\sum_{i=1}^q \lambda_i + p\tau^2}.$$

答案:

1) 由于$A\Sigma A^\top$的秩最多为q，其后$p-q$个特征值均为0。因此只有前q个主成分可能有效。

2) 首先我们可以求出此时自变量的协方差矩阵

$$\mathrm{Cov}(\mathbf{X}) = A\Sigma A^\top + \tau^2 I$$

．假设λ为$A\Sigma A^\top$的任一特征值，而$\mathbf{v}$为对应的特征向量，我们知道$A\Sigma A^\top \mathbf{v} = \lambda \mathbf{v}$．而进一步有

$$\left(A\Sigma A^\top + \tau^2 I\right)\mathbf{v} = \lambda\mathbf{v} + \tau^2\mathbf{v} = (\lambda + \tau^2)\mathbf{v}.$$

从而$\mathbf{v}$也是$A\Sigma A^\top + \tau^2 I$的特征向量，对应的特征值为$\lambda + \tau^2$． $\mathrm{Cov}(\mathbf{X})$的前q个特征值即为$\lambda_1 + \tau^2, \ldots, \lambda_q + \tau^2$．

3) 由于$A\Sigma A^\top$的后$p-q$个特征值均为**0**，根据**2)**中的推导，$A\Sigma A^\top + \tau^2 I$的后$p-q$个特征值均为$\tau^2$．因此，前$q$个主成分代表的信息占总信息的比例为

$$\frac{\sum_{i=1}^q (\lambda_i + \tau^2)}{\sum_{i=1}^q (\lambda_i + \tau^2) + (p-q)\tau^2} = \frac{\sum_{i=1}^q \lambda_i + q\tau^2}{\sum_{i=1}^q \lambda_i + p\tau^2}.$$