2024 Fall: High-dimensional Data Analysis

Midterm Exam Solutions

说明：

1. 期中考试时间为2024年11月4日10:05-12:05。
2. 总共七道大题，总分100分。
3. 除笔以外，不允许带任何其它工具 (包括自己的草稿纸)。手机请一律交到讲台上。
4. 请将答案统一写在答题纸上。
5. 步骤分将占有重要比例，请写清楚解题过程。

Problem 1 (10 pts). 判断题，请判断以下说法为正确 (T) 或者错误 (F)。

1) 回归$Y \sim X_1$的RSS一定不小于$Y \sim X_1 + X_2$的RSS。（ T ）

2) 对于线性回归模型来说，模型包含的变量越多，则预测误差越小。(F)

3) 在线性回归的岭回归方法中，tuning parameter λ 越大，则预测时方差越大，偏差平方越小。(F)

4) 对非线性回归模型来说，参数估计的Gauss-Newton算法总是能够收敛到全局最优解。（ F ）

5) 当n较大时，BIC对于变量数的惩罚比AIC更加严厉 (换句话说，BIC选出的变量数一般不会多于AIC)。（ T ）

Problem 2 (16 pts). 单选题，每题只有一个正确答案。

1) 在线性回归中，下面哪一个量仅依赖于自变量，而不依赖于因变量？（ B ）

(A) 最小二乘估计量$\widehat{\boldsymbol{\beta}}$

(B) 第一个主成分的载荷 (loadings)

(C) 残差平方和RSS

(D) R^2

2) 下面哪种变量选择方法不适用于$p > n$的情形？（ B ）

(A) 向前选变量法 (forward selection)

(B) 向后选变量法 (backward elimination)

(C) 岭回归 (ridge regression)

(D) lasso

3) 下列哪个模型可以直接转化为一个线性模型？(其中θ_1^*, θ_2^*为未知参数) (A)

(A) $y_i = \theta_1^* + \exp(\theta_2^* + \log x_i) + e_i$

(B) $y_i = \theta_1^* + \exp(\theta_2^* \log x_i) + e_i$

(C) $y_i = \theta_1^* + \log(\theta_2^* + x_i) + e_i$

(D) $y_i = \theta_1^* \exp(\theta_2^* x_i) + e_i$

4) 下列关于logistic回归的说法正确的是 (D)

(A) 自变量只允许是连续型的

(B) 因变量只能是0-1变量

(C) 成功概率为自变量的一个线性组合

(D) 回归的G^2 (deviance) 越小，说明模型拟合得越好

Problem 3 (14 pts). 假设如下回归模型

$$y_i = \beta_0^* + \beta_1^* x_i + \beta_2^*(3x_i^2 - 2) + e_i, \quad i = 1, 2, 3.$$

其中$e_i \overset{i.i.d.}{\sim} N(0, \sigma^{*2})$. 我们给定自变量的值$x_1 = -1$, $x_2 = 0$, $x_3 = 1$, 而因变量的值则用y_1, y_2, y_3表示。

1) (8 pts) 求出$\beta_0^*, \beta_1^*, \beta_2^*$的最小二乘估计量。

2) (6 pts) 证明：当已知$\beta_2^* = 0$时，β_0^*, β_1^*的最小二乘估计量保持不变。

答案:

1) 我们写出矩阵X

$$\mathbf{X} = \begin{bmatrix} 1 & -1 & 1 \\ 1 & 0 & -2 \\ 1 & 1 & 1 \end{bmatrix}.$$

可以算出

$$\mathbf{X}^\top \mathbf{X} = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 6 \end{bmatrix}.$$

进一步可以算出

$$\widehat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} = \begin{bmatrix} (y_1 + y_2 + y_3)/3 \\ (-y_1 + y_3)/2 \\ (y_1 - 2y_2 + y_3)/6 \end{bmatrix}.$$

2) 此时

$$\mathbf{X} = \begin{bmatrix} 1 & -1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

同样可以求得

$$\widehat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} = \begin{bmatrix} (y_1 + y_2 + y_3)/3 \\ (-y_1 + y_3)/2 \end{bmatrix}.$$

Problem 4 (16 pts). 在一个线性回归中有连续因变量Y, 有一个连续自变量X与一个分类变量F, 其中F有两个类别$\{A, B\}$. 样本数为$n = 8$. 我们分别拟合三个模型，得到如下结果：

表 1: 模型1：$Y \sim X$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	32.31	2.00	16.16	3.58E-06
X	14.32	0.70	20.46	8.87E-07
R-squared: 0.34				

表 2: 模型2：$Y \sim X + F$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	29.66	2.04	14.54	1.39E-05
X	14.57	0.69	21.12	2.21E-06
B	3.83	0.74	5.18	1.77E-03
R-squared: 0.50				

表 3: 模型3：$Y \sim X + F + X : F$

	Estimate	Std. Error	t value	Pr($>|t|$)
(Intercept)	30.36	2.86	10.62	2.22E-04
X	14.33	0.98	14.62	6.36E-05
B	2.47	3.96	0.62	0.28
$X : B$	0.48	1.38	0.35	0.37
R-squared: 0.64				

1) (4 pts) 从模型的基本设定方面，简述三个模型在回归的截距以及X的斜率上有何区别。

2) (4 pts) 对于模型2，请构建X回归系数的一个95%置信水平的置信区间 (允许用符号表示t-分布的分位数)。判断0是否被包含在这个置信区间之内。

3) (4 pts) 如果用t-检验的显著性为判断依据来选择模型，最合理的模型应该是什么样的？

4) (4 pts) 如果用R^2_{adj}为判断依据来选择，应该用哪一个模型？

答案:

1) 模型一：F的每个类别共用截距及斜率。

模型二：F的每个类别仅共用斜率。

模型三：F的每个类别有各自的截距及斜率。

2) 置信区间应为

$$[14.57 \pm 0.69 \cdot t_{0.025}(5)].$$

由于相应的假设检验5%在的显著水平下拒绝系数为0的原假设，因此置信区间应该不包含0.

3) 模型3中，$X:B$的系数经检验为0，因此把这个高阶项去除。再拟合模型2时，所有系数都显著非零，因此应该选择模型2。

4) 根据公式

$$R^2_{\text{adj}} = 1 - \frac{n-1}{n-k-1}(1-R^2)$$

可以计算出三个模型的R^2_{adj}分别为0.23, 0.3, 0.37. 因此选择模型3。

Problem 5 (15 pts). 在一个logistic回归中，因变量Y是一个0-1变量，有三个连续型自变量X_1, X_2, X_3. 我们拟合模型 $Y \sim X_1 + X_2 + X_3$, 得到如表4的结果。

表 4: Logistic模型$Y \sim X_1 + X_2 + X_3$的结果

	Estimate	Std. Error	z value	$\Pr(>\|z\|)$
(Intercept)	-15.55	7.29	-2.13	0.033
X_1	-0.59	0.36	(a)	0.10
X_2	0.56	0.33	1.70	0.089
X_3	1.96	(b)	2.23	(c)
Residual deviance: 14.18 on 16 degrees of freedom				

1) (5 pts) 用表4中给出的数字计算缺失的(a)-(c)值。只需要给出计算式，不要求计算结果。

2) (5 pts) 假设$x_1 = 5$, $x_2 = 25$. 根据表4的结果，我们需要选定怎样的x_3值才能使得$y = 1$的概率为40%? 只需要给出计算式，不要求计算结果。

3) (5 pts) AIC一般定义为

$$\text{AIC} = -2\log(\text{maximum likelihood}) + 2 \cdot \text{number of parameters}.$$

现在我们拟合一个不含X_1的模型，得到如表5的结果。 如果用AIC作为模型选择准则，应该选用哪个模型? (提示：Residual deviance即logistic回归的deviance, 定义为$G^2 = 2(l^s - \hat{l})$, 其中l^s与$\hat{l}$分别为饱和模型以及logistic模型的最大对数似然函数值。)

答案:

表 5: Logistic模型$Y \sim X_2 + X_3$的结果

	Estimate	Std. Error	z value	$\Pr(>\|z\|)$
(Intercept)	-7.60	4.44	-1.71	0.087
X_2	0.087	0.14	0.60	0.55
X_3	1.53	0.68	2.25	0.024
Residual deviance: 18.16 on 17 degrees of freedom				

1) $(a) = -0.59/0.36$.

$(b) = 1.96/2.23$.

$(c) = 2(1 - \Phi(2.23))$.

2) x_3应该满足

$$\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3 = \log\left(\frac{\theta}{1-\theta}\right).$$

于是

$$\begin{aligned} x_3 &= \left\{\log\left(\frac{40\%}{60\%}\right) - \hat{\beta}_0 - \hat{\beta}_1 x_1 - \hat{\beta}_2 x_2\right\} / \hat{\beta}_3 \\ &= \left\{\log\left(\frac{2}{3}\right) + 15.55 + 0.59 \times 5 - 0.56 \times 25\right\} / 1.96. \end{aligned}$$

3) 我们知道residual deviance为

$$G^2 = 2(l^s - \hat{l}),$$

则用AIC等价于用(residual deviance + 2· number of parameters)，两者之间只差一个不依赖于模型的常数$2l^s$.

对于全模型，这个量为$14.18 + 2 \times 4$. 对于缺少X_3的模型，这个量为$18.16 + 2 \times 3$, 比全模型大。因此我们应选择全模型。

Problem 6 (15 pts). 考虑一个简单线性模型

$$y_i = \beta_0^* + \beta_1^* x_i + e_i, \quad i = 1, \ldots, n,$$

其中$e_i \overset{i.i.d.}{\sim} N(0, \sigma^{*2})$. 现在对于某给定函数$g(x)$, 定义$z_i = g(x_i)$. 让$\bar{z} = \sum_{i=1}^n z_i/n$. 考虑$\beta_1^*$的一个估计量

$$\widetilde{\beta}_1 = \frac{\sum_{i=1}^n (z_i - \bar{z}) y_i}{\sum_{i=1}^n (z_i - \bar{z}) x_i}.$$

1) (5 pts) 证明: $\widetilde{\beta}_1$是无偏的。

2) (5 pts) 证明：

$$\mathrm{Var}(\widetilde{\beta}_1) = \frac{\sum_{i=1}^n (z_i - \bar{z})^2}{\{\sum_{i=1}^n (z_i - \bar{z}) x_i\}^2} \sigma^{*2}.$$

3) (5 pts) 记β_1^*最小二乘估计量为$\hat{\beta}_1$. 我们知道，

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x}) x_i}.$$

证明：

$$\mathrm{Var}(\hat{\beta}_1) \le \mathrm{Var}(\widetilde{\beta}_1).$$

(提示：可以利用柯西-施瓦茨不等式

$$\left\{ \frac{1}{n} \sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x}) \right\}^2 \le \left\{ \frac{1}{n} \sum_{i=1}^n (z_i - \bar{z})^2 \right\} \left\{ \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right\}.$$

)

答案:

1) 可以计算出

$$\begin{aligned}
\mathrm{E}(\widetilde{\beta}_1) &= \frac{\sum_{i=1}^n (z_i - \bar{z}) \mathrm{E}(y_i)}{\sum_{i=1}^n (z_i - \bar{z}) x_i} \\
&= \frac{\sum_{i=1}^n (z_i - \bar{z})(\beta_0^* + \beta_1^* x_i)}{\sum_{i=1}^n (z_i - \bar{z}) x_i} \\
&= \beta_0^* \frac{\sum_{i=1}^n (z_i - \bar{z})}{\sum_{i=1}^n (z_i - \bar{z}) x_i} + \beta_1^* \frac{\sum_{i=1}^n (z_i - \bar{z}) x_i}{\sum_{i=1}^n (z_i - \bar{z}) x_i} \\
&= \beta_1^*.
\end{aligned}$$

2) 可以计算出

$$\begin{aligned}
\mathrm{Var}(\widetilde{\beta}_1) &= \frac{\sum_{i=1}^n (z_i - \bar{z})^2 \mathrm{Var}(y_i)}{\{\sum_{i=1}^n (z_i - \bar{z}) x_i\}^2} \\
&= \frac{\sum_{i=1}^n (z_i - \bar{z})^2 \sigma^{*2}}{\{\sum_{i=1}^n (z_i - \bar{z}) x_i\}^2}.
\end{aligned}$$

3) 我们知道

$$\mathrm{Var}(\hat{\beta}_1) = \frac{\sigma^{*2}}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

利用$\sum_{i=1}^{n}(z_i-\bar{z})x_i=\sum_{i=1}^{n}(z_i-\bar{z})(x_i-\bar{x})$以及柯西-施瓦茨不等式，结论得证。

Problem 7 (14 pts). 假设有$2m+n$个因变量的样本$y_1,\dots,y_{2m+n}$, 分为三组，分别满足

$$\begin{aligned}
y_i &= \theta^* + e_i, \quad 1 \le i \le m,\\
y_i &= \theta^* + \phi^* + e_i, \quad m+1 \le i \le 2m,\\
y_i &= \theta^* - 2\phi^* + e_i, \quad 2m+1 \le i \le 2m+n,
\end{aligned}$$

其中$e_i \overset{i.i.d.}{\sim} N(0,\sigma^{*2})$.

1) (7 pts) 求出θ^*与ϕ^*的最小二乘估计量$\hat{\theta}$与$\hat{\phi}$。

2) (7 pts) 证明：当$m=2n$时，1)中求得的$\hat{\theta}$与$\hat{\phi}$相关系数为0。

答案:

1) 首先，最小二乘法的目标函数为

$$\min_{\theta,\phi}\left\{\sum_{i=1}^{m}(y_i-\theta)^2+\sum_{i=m+1}^{2m}(y_i-\theta-\phi)^2+\sum_{i=2m+1}^{2m+n}(y_i-\theta+2\phi)^2\right\}$$

对θ与ϕ分别求偏导，得到

$$\begin{aligned}
&-2\sum_{i=1}^{m}(y_i-\theta)-2\sum_{i=m+1}^{2m}(y_i-\theta-\phi)-2\sum_{i=2m+1}^{2m+n}(y_i-\theta+2\phi)=0\\
&-2\sum_{i=m+1}^{2m}(y_i-\theta-\phi)+4\sum_{i=2m+1}^{2m+n}(y_i-\theta+2\phi)=0.
\end{aligned}$$

我们让$S_1=\sum_{i=1}^{m}y_i$, $S_2=\sum_{i=m+1}^{2m}y_i$, $S_3=\sum_{i=2m+1}^{2m+n}y_i$, 分别为三组因变量的样本之和。则上面两式转化为

$$\begin{aligned}
&(S_1-m\theta)+(S_2-m\theta-m\phi)+(S_3-n\theta+2n\phi)=0\\
&(S_2-m\theta-m\phi)-2(S_3-n\theta+2n\phi)=0.
\end{aligned}$$

求得

$$\begin{aligned}
\hat{\theta}&=\frac{(m+4n)S_1+6nS_2+3mS_3}{m(m+13n)}\\
\hat{\phi}&=\frac{(2n-m)S_1+(m+3n)S_2-5mS_3}{m(m+13n)}.
\end{aligned}$$

2）我们知道$\mathrm{Var}(S_1) = \mathrm{Var}(S_2) = m\sigma^{*2}$**,** $\mathrm{Var}(S_3) = n\sigma^{*2}$**, 且**$S_1, S_2, S_3$**互相独立。因此**

$$\begin{aligned}
\mathrm{Cov}(\hat{\theta}, \hat{\phi}) &= \frac{1}{m^2(m+13n)^2}\left\{(m+4n)(2n-m)\mathrm{Var}(S_1) + 6n(m+3n)\mathrm{Var}(S_2) - 15m^2\mathrm{Var}(S_3)\right\} \\
&= \frac{\sigma^{*2}}{m^2(m+13n)^2}\left\{(m+4n)(2n-m)m + 6n(m+3n)m - 15m^2n\right\} \\
&= \frac{\sigma^{*2}}{m^2(m+13n)^2}m(13n+m)(2n-m) \\
&= \frac{\sigma^{*2}}{m(m+13n)}(2n-m)
\end{aligned}$$

显然当$m = 2n$**时，此协方差为0.**